

TODO ②: Pü4

A: Stokes

N: Constrained Optimization, KKT

Globalübung 13

- Mathe 3 -

03.02.21
Lambert Thiesen ①

②: → Pü4 am Donnerstag QR QR/mit Shift gr()

→ Letzte Gü: Fragestunde? (E-Mail Ankündigung) ↳ Altklausur Aufgaben ✓


A Satz von Stokes

Für stetig diffbares Vektorfeld f auf regulärerem Fläche F gilt

rot f neu in 3D definiert.

$$\vec{f} = \begin{pmatrix} f_1 \\ f_2 \\ 0 \end{pmatrix}$$

$$\int_F \text{rot } f \cdot \nu \, d\sigma = \int_{\gamma} f \cdot ds$$



wobei γ parametrisiert Randkurve ∂F mit positiver Orientierung

("Fläche liegt links beim Durchlaufen von γ ")

Beispiel: Sei $f \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 3x_2 \\ -x_1 x_3 \\ x_2 x_3^2 \end{pmatrix}$ sowie die Fläche

$$F = \left\{ \underbrace{x_3 \geq \frac{1}{2}(x_1^2 + x_2^2)}_{x_1^2 + x_2^2 \leq 2} \wedge x_3 = 2 \mid \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \in \mathbb{R}^3 \right\}. \text{ Verifiziere Stokes.}$$

II) Berechne RHS: $\int_{\gamma} f \cdot ds$


$$\text{Randkurve } \gamma(t) = \begin{pmatrix} 2 \cos(t) \\ 2 \sin(t) \\ 2 \end{pmatrix}, t \in [0, 2\pi]$$

ist "positiv orientiert." ✓

$$\text{Daher } \int_{\gamma} f \cdot ds = \int_0^{2\pi} \langle f(\gamma(t)), \gamma'(t) \rangle dt$$

Gü 10: Arbeitsintegral

$$\text{mit } \gamma'(t) = \begin{bmatrix} -2 \sin(t) \\ 2 \cos(t) \\ 0 \end{bmatrix}, f(\gamma(t)) = \begin{bmatrix} 6 \cdot \sin(t) \\ -4 \cos(t) \\ 4 \sin(t) \cos^2(t) \end{bmatrix}$$



$$\Rightarrow \int_{\gamma} f \cdot ds = \int_0^{2\pi} \left\langle \begin{bmatrix} -2\sin(t) \\ 2\cos(t) \\ 0 \end{bmatrix}, \begin{bmatrix} 6\sin(t) \\ -4\cos(t) \\ 4\sin(t)\cos^2(t) \end{bmatrix} \right\rangle dt \quad (2)$$

RHS Stokes

$$= \int_0^{2\pi} [-12\sin^2(t) - 8\cos^2(t)] dt$$

$$= \int_0^{2\pi} [-12(1 - \cos^2(t)) - 8\cos^2(t)] dt$$

$$= -12 \int_0^{2\pi} 1 dt + 4 \underbrace{\int_0^{2\pi} \cos^2(t)}_{\pi} = -24\pi + 4\pi = -20\pi$$

II) LHS : $\int_F \operatorname{rot} f \cdot \nu \, ds$


$$\nabla_x f = \begin{bmatrix} \partial_{x_2} f_3 - \partial_{x_3} f_2 \\ \partial_{x_3} f_1 - \partial_{x_1} f_3 \\ \partial_{x_1} f_2 - \partial_{x_2} f_1 \end{bmatrix} = \begin{bmatrix} x_3^2 - (-x_1) \\ 0 - 0 \\ -x_3 - 3 \end{bmatrix} = \begin{bmatrix} x_1 + x_3^2 \\ 0 \\ -x_3 - 3 \end{bmatrix}$$

Fläche F : $\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \Phi(r, \varphi) = \begin{pmatrix} r \cos \varphi \\ r \sin \varphi \\ 2 \end{pmatrix} \quad \begin{array}{l} 0 \leq r \leq 2 \\ 0 \leq \varphi \leq 2\pi \end{array}$

$$\Rightarrow \|\nu\|_2 = \left\| \frac{\partial \Phi}{\partial r} \times \frac{\partial \Phi}{\partial \varphi} \right\|_2$$

$$= \left\| \begin{pmatrix} \cos \varphi \\ \sin \varphi \\ 0 \end{pmatrix} \times \begin{pmatrix} -r \sin \varphi \\ r \cos \varphi \\ 0 \end{pmatrix} \right\|_2 = \left\| \begin{pmatrix} 0 \\ 0 \\ r \cos^2 \varphi + r \sin^2 \varphi \end{pmatrix} \right\|_2 = r$$

$$\Rightarrow \nu = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \left(= \frac{\partial \Phi / \partial r \times \partial \Phi / \partial \varphi}{\|\partial \Phi / \partial r \times \partial \Phi / \partial \varphi\|_2} \right)$$



$$\Rightarrow \int_F \operatorname{rot} f \cdot \nu \, ds = \int_0^2 \int_0^{2\pi} (\operatorname{rot} f)(\Phi(r, \varphi)) \cdot \nu \, d\varphi \, dr$$

$$= \int_0^2 \int_0^{2\pi} \begin{pmatrix} r \cos \varphi + r^2 \sin^2 \varphi \\ 0 \\ -3 - 2 \end{pmatrix} \cdot \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \, d\varphi \, dr$$

$$= \int_0^2 \int_0^{2\pi} -5 \, d\varphi \, dr = \int_0^2 -10\pi \, dr = -20\pi$$

Stokes verifiziert weil $LHS = RHS$.

IN Constraint Optimization

$$\min_{x \in \mathbb{R}^n} f(x) \quad \text{subject to} \quad \begin{cases} g_i(x) \geq 0 \\ h_j(x) = 0 \end{cases}$$

$$\begin{aligned} f: \mathbb{R}^n &\rightarrow \mathbb{R} \\ g: \mathbb{R}^n &\rightarrow \mathbb{R}^m \\ h: \mathbb{R}^n &\rightarrow \mathbb{R}^q \end{aligned}$$

LP (Linear Progr.): f, g, h linear

NLP (Nonlinear Prog.): f oder g oder h nicht linear

Feasibility Region X : $\min_{x \in X} f(x)$ mit $X = \{x \in \mathbb{R}^n \mid g_i(x) \geq 0, h_j(x) = 0\}$

Minimizer: $x^* = \underset{x \in X}{\operatorname{argmin}} f(x)$

KKT-Bedingungen: Sind notwendig für kritischen Punkt (Min, Max, Sattel)
(Wenn bestimmte Regularität \rightarrow K(Q))

→ Aber wo kommen die her?

Equality Constraints: Betrachte

$$\begin{cases} \min f(x) \\ \text{s.t. } h(x) = 0 \end{cases}$$


→ Wir wollen natürlich ein x^* mit : $h(x^*) = 0$ A)

→ Weiterhin: $\nabla h(x^*)$ muss parallel zu $\nabla f(x^*)$.

Warum?: Sei $X: (-1, 1) \rightarrow X = \{x \mid h(x)\}$ Parab. mit

$$X(0) = x^*$$

$$\begin{aligned} X: (-1, 1) &\rightarrow X \\ X &= \{x \mid h(x) = 0\} \end{aligned}$$



Nun gehen entlang $F(t) := f(X(t))$. Wir haben $f(X(0)) = f(x^*) = F(0)$ ist kritisches Pkt.

kritischer Punkt heißt: $f'(0) = 0 \Rightarrow \frac{d}{dt} f(X(t)) \Big|_{t=0} = 0$

Kettenregel

 $\Rightarrow \nabla f(\underbrace{X(0)}_{x^*})^T \cdot X'(0) = 0 \Leftrightarrow \boxed{\nabla f(x^*) \perp X'(0)}$

ist eig.
esgal. ↓ (4)

Weiterhin ist ja per Definition: $h(X(t)) = 0 \quad \forall t \Rightarrow \frac{d}{dt} h(X(t)) \Big|_{t=0} = 0 \Rightarrow \boxed{\nabla h(x^*) \perp X'(0)}$

Daher im kritischen Punkt x^* : $\boxed{\nabla f(x^*) \parallel \nabla h(x^*) \Leftrightarrow \nabla f(x^*) = \lambda^* \nabla h(x^*)}$

3

Jetzt cleverer Idee

$\mu^* \in \mathbb{R}$

Definiere Lagrange function: $l(x, \mu) := f(x) - \mu h(x)$ why?


und sodann ein $\mu^* \in \mathbb{R}$ $\nabla l(x^*, \mu^*) = \begin{bmatrix} \nabla_x l(x^*, \mu^*) \\ \nabla_\mu l(x^*, \mu^*) \end{bmatrix} = \begin{bmatrix} \nabla f(x^*) - \mu^* \nabla h(x^*) \\ -h(x^*) \end{bmatrix} \stackrel{!}{=} \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ (3) (A)

→ Das kombiniert A & B!

Inequality Constraint

[A] $g(x^*) \geq 0$ (Det)

wie in
Güte



I) Inactive ($g(x^*) > 0$) $\Rightarrow \boxed{\nabla f(x^*) = 0}$ [B1]

II) Active ($g(x^*) = 0$) $\Rightarrow \boxed{\nabla f(x^*) = \lambda^* \nabla g(x^*)}$ [B2] (Wie oben)

↳ Siehe oben

[C] $\lambda^* \geq 0$

→ $\lambda^* \geq 0$ muss sein sodass $\nabla f(x^*)$ und $\nabla g(x^*)$ in entgegengesetzte Richtg. für Minimum.

→ Kombination von [A], [B1], [B2], [C]:

... nur active ...

$\left\{ \nabla f(x^*) - \lambda^* \nabla g(x^*) = 0 \right.$

$g(x^*) \geq 0$

[A]

$\lambda^* \geq 0$

[C]

$g(x^*) \lambda^* = 0$

Komplementär

[B1] + [B2]

weil $g(x^*) = 0$ 31

weil $g(x^*) > 0$ 32

weil $\lambda^* = 0$ dann ✓

Karush-Kuhn-Tucker Bedingungen (kombiniert alle Bd. für mehrere Constraints) (5)

$$\left\{ \begin{array}{l} \nabla h(x, \lambda, \mu) = \nabla f(x) - \sum_{i=1}^m \lambda_i \nabla g_i(x) - \sum_{j=1}^q \mu_j \nabla h_j(x) = 0 \\ h(x) = 0 \\ g_i(x) \leq 0 \\ \lambda_i \geq 0 \\ g_i(x) \lambda_i = 0 \end{array} \right.$$

mit $x \in \mathbb{R}^n$, $\lambda \in \mathbb{R}^m$, $\mu \in \mathbb{R}^q$. KKT-Point $\hat{=} (x^*, \lambda^*, \mu^*)$ wenn Bd. erfüllt.
kritische Punkte Lagrange Multipliz.

Nun: Berechnung der Kandidaten als KKT-Punkte?

Problem: Es gibt NLP für die das Minimum kein KKT Punkt ist.
(Nur wenn bestimmte Glättungs/Regularitäts-eigenschaften erfüllt sind)

LICQ: ("Linear Independence Constraint Qualification")

Punkt $x \in X$ hat LICQ falls: $\left(\left\{ \nabla h_j(x) \right\}_{j=1}^q, \left\{ \nabla g_i(x) \right\}_{i \in I_g(x)} \right)$ linear unabhängig

mit $I_g(x) = \left\{ i \in \{1, \dots, m\} \mid g_i(x) = 0 \right\}$ Menge aller aktiven Bedingungen
z.B. $I_g(x) = \{1, 2, 5, 8\}$

\Rightarrow Wenn LICQ gilt, dann sind KKT FONC für kritische Punkte x^*
(1st-order necessary condition) (wie $\nabla f = 0$)

In der Praxis: I) Potentielle KKT Punkte finden
II) LICQ dort prüfen
III) Falls LICQ gilt \Rightarrow Hessematrix (23) untersuchen für Min/Max/Sat.
HW 2nd $\nabla^2 f > 0$
 \Rightarrow min

Demo : KKT & LICQ

Define Lagrangian


$$\mathcal{L}(x, \lambda, \mu) = f(x) - \sum_{i=1}^m \lambda_i g_i(x) - \sum_{j=1}^q \mu_j h_j(x)$$

```
lagrangian (generic function with 1 method)
- function lagrangian(x, f, g, h, xs, ms, lg)
-   # TODO: include only active gs with lg
-   return (
-     f(x)
-     # - reduce(+, [g[i](x) * xs[i] for i=1:size(g)[1]], init=0) # TODO: include
-     # - reduce(+, [h[i](x) * ms[i] for i=1:size(h)[1]], init=0)
-   )
- end

-μ(-5x₂ + (x₁ - 1)²) + (x₁ - 1)² + (x₂ - 2)²

lagrangian(x, f1, [], h, lambdas, mus, [])
```

Visualize KKT Points



Linear Independence Constraint Quality (LICQ)

Point $x \in X$ satisfies LICQ if:

$$\{\nabla h_j(x)\}_{j=1}^q, \{\nabla g_i(x)\}_{i \in I_g(x)}$$

are linearly independent. The set of active inequality constraints at point x is labelled with $I_g(x)$.

Index Set of Active Constraints:

```
lg (generic function with 1 method)
- function lg(x,g)
-   set = []
-   for i in 1:size(g)[1]
-     if g[i](x) == 0
-       push!(set, i)
-     end
-   end
-   return set
```

LICQ (generic function with 1 method)
- function LICQ(s, g, lg, h)
- set = []
- for i in 1:size(g)[1]
- if lg(g[i])(x) == 0
- push!(set, i)
- end
- end
- for i in 1:size(h)[1]
- if lg(h[i])(x) == 0
- push!(set, i)
- end
- end
- if length(set) > 1
- for i in 1:length(set)
- for j in 1:i-1
- if dot(g[set[i]](x), g[set[j]](x)) == 0
- push!(set, j)
- break
- end
- end
- end
- end
- return set

I) KTT 1) $\begin{pmatrix} x^* \\ y^* \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$

2) $\begin{pmatrix} x^* \\ y^* \end{pmatrix} = \begin{pmatrix} -5 \\ 8 \end{pmatrix}$

$\nabla f^2 \begin{pmatrix} x^* \\ y^* \end{pmatrix} = \begin{bmatrix} 5 & 0 \\ 0 & 8 \end{bmatrix} > 0$

MIN

Kandidaten